순천향대학교

ARTIFICIAL INTELLIGENCE CONVERGENCE SOFTWARE
순천향대학교 인공지능 융합 소프트웨어 연구실

Gradient Descent & BackPropagation

신동화

발표 | 신동화
010 – 5466 – 3672
ek65110112@gmail.com
순천향대학교 멀티미디어관 M508

CONTENTS

01 Gradient Descent (GD) | GD 문제점 | Weight 초기화 |

02 Stochastic GD

03 Mini-Batch GD | Batch Size | Learning Rate |

04 BackPropagation

01 | Gradient Descent 경사 하강법

초기 θ 에서 시작하여 θ를 변경하면서 J(θ)를 줄여나가는 방법

$$J(\theta) = \frac{1}{2}\sum_{i=1}^{m}\left(\underbrace{h_\theta(x^i) - y^i}_{\text{error (e차)}}\right)^2$$

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

- Batch Gradient Descent
- Stochastic Gradient Descent
- Mini-Batch Gradient Descent

01 | Gradient Descent 경사 하강법과 학습률

Learning rate : 한번에 얼만큼 이동할지 결정하는 파라미터

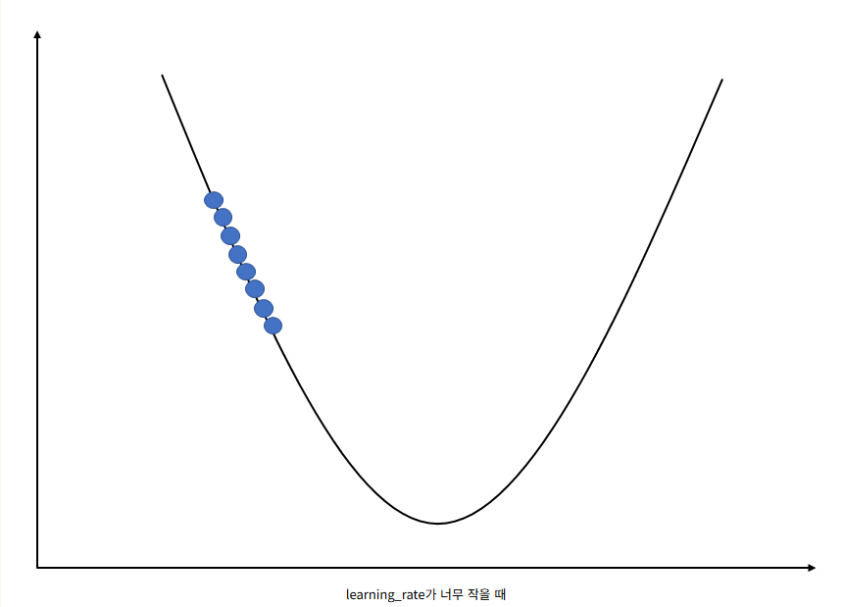

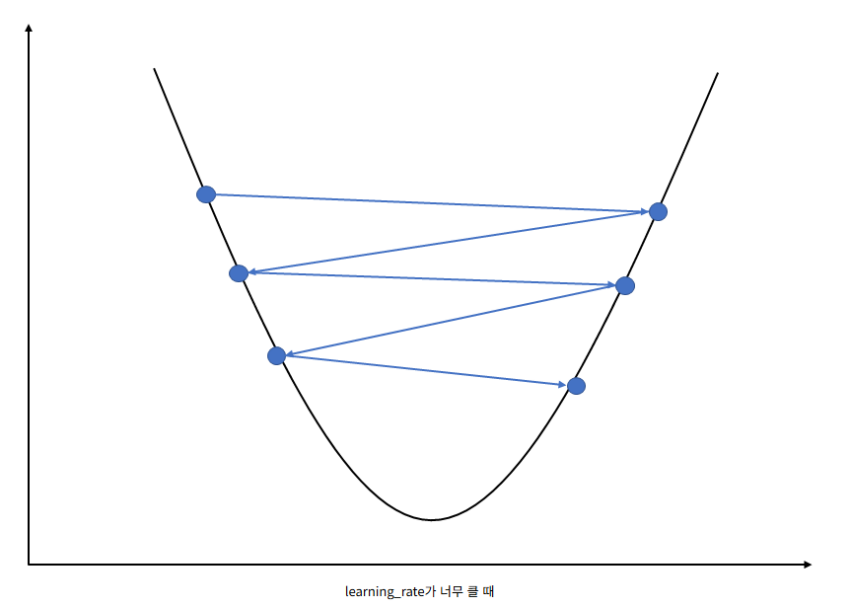

- Learning rate가 너무 작을 때
- Learning rate가 너무 클 때

01 | Gradient Descent

Batch Gradient Descent

전체 학습 데이터를 모두 사용해 한 번의 업데이트에 필요한 기울기 (gradient)를 계산하고 θ를 갱신하는 방법

1. 가중치를 평균 0, 분산 σ^2인 정규분포에서 랜덤 초기화 한다 $\sim N(0,\sigma^2)$
2. 손실을 가중치로 미분한 값(기울기)을 계산한다 $\frac{\partial J(W)}{\partial W}$
3. 가중치를 기울기 반대 방향으로 학습률 만큼 반환한다 $W \leftarrow W - \eta \frac{\partial J(W)}{\partial W}$
4. 수렴할 때까지 반복한다
5. 학습된 가중치를 반환한다 (학습 종료)

01 | Gradient Descent

Batch Gradient Descent

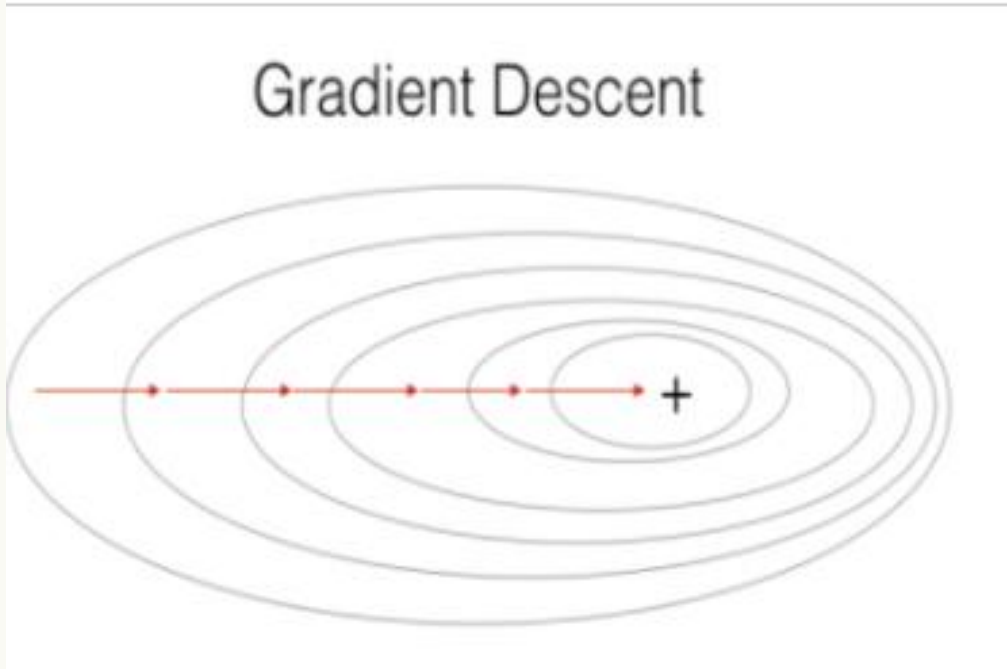

- 전체 업데이트가 한번에 이루어지므로 계산 횟수가 적다

- 전체 데이터에 대해 미분 값을 계산하여 갱신하므로 안정적으로 수렴해간다

01 | Gradient Descent

배치 경사 하강법의 문제점

1. 계산 속도가 느리다.

- 전체 데이터를 모두 고려
- 대규모 데이터 셋에서 비효율적

2. Local Minimum에 빠질 수 있다

01 | Gradient Descent

배치 경사 하강법의 문제점

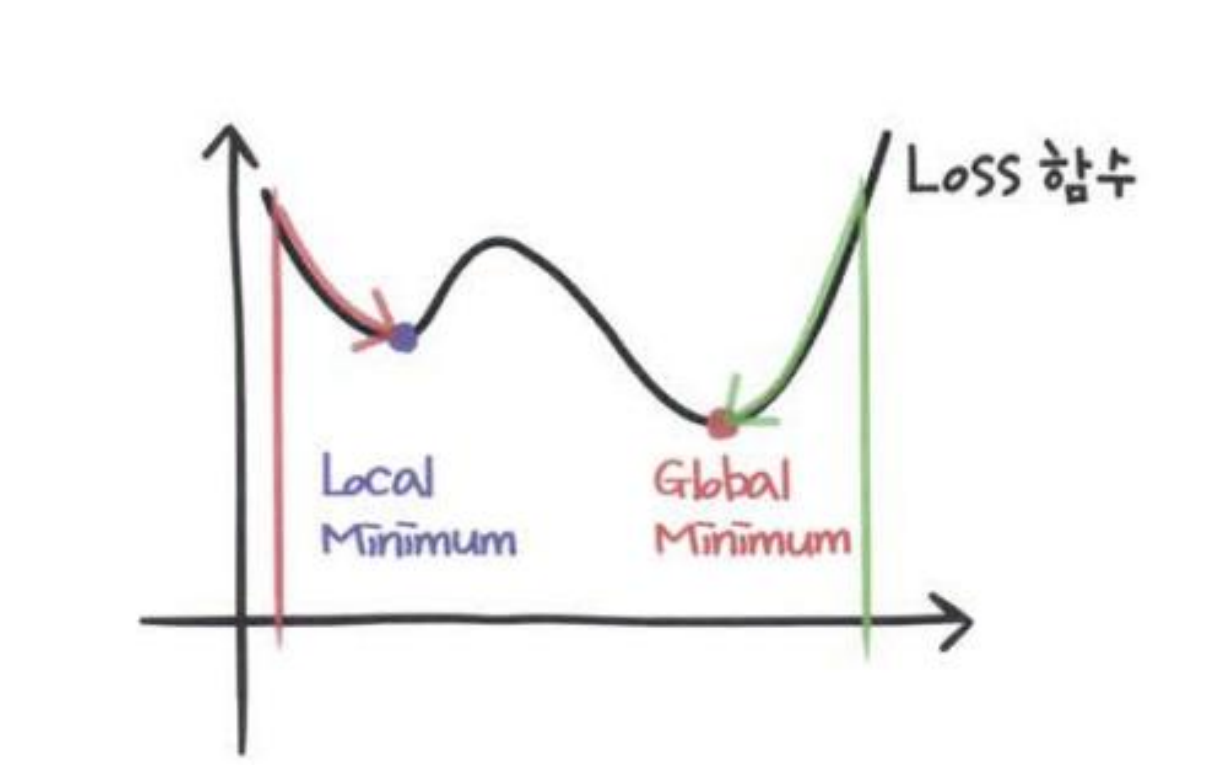

01 | Gradient Descent

Weight 초기화

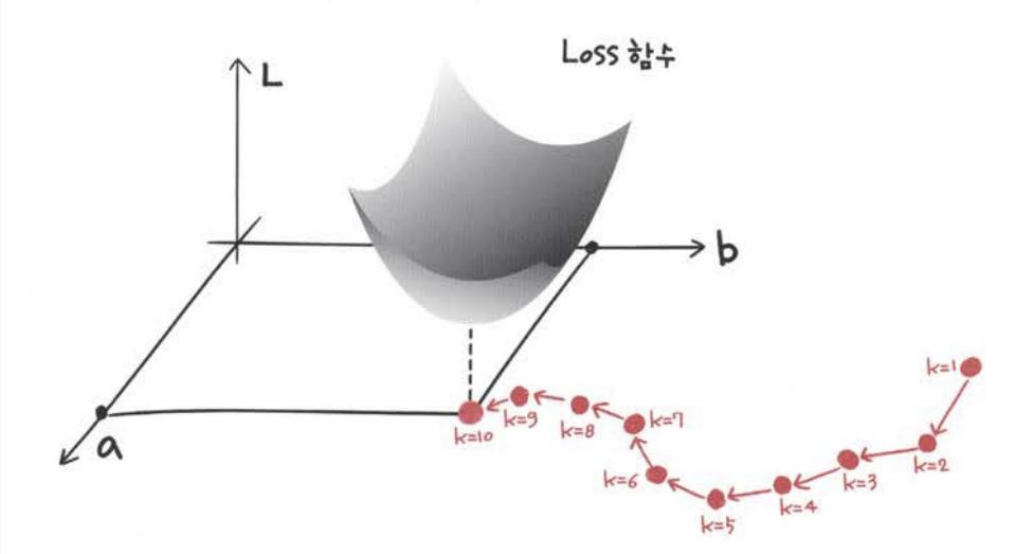

파라미터의 초깃값이 최소점으로부터 멀리 떨어져 있을수록 최적값에 도달하기 위해 많은 업데이트가 필요

- 부적절한 초기화(분산 과대) : Gradient Exploding (기울기 폭발)
- 부적절한 초기화(분산 과소) : Gradient Vanishing (기울기 소실)

01 | Gradient Descent

Weight 초기화

Lecun 초기화

$$w \sim U\left(-\sqrt{\frac{3}{N_{\text{in}}}}, \sqrt{\frac{3}{N_{\text{in}}}}\right) \text{ 또는 } w \sim N\left(0, \frac{1}{N_{\text{in}}}\right)$$

- 가우시안 분포는 0 주변에 더 집중된 값을 선택

kaiming 초기화

$$w \sim U\left(-\sqrt{\frac{6}{N_{\text{in}}}}, \sqrt{\frac{6}{N_{\text{in}}}}\right) \text{ 혹은 } w \sim N\left(0, \frac{2}{N_{\text{in}}}\right)$$

- ReLU 활성화 함수를 사용하는 신경망에서 효과적

Xavier 초기화

$$w \sim U\left(-\sqrt{\frac{6}{N_{\text{in}}+N_{\text{out}}}}, \sqrt{\frac{6}{N_{\text{in}}+N_{\text{out}}}}\right) \text{ 혹은 } w \sim N\left(0, \frac{2}{N_{\text{in}}+N_{\text{out}}}\right)$$

- Sigmoid나 tanh와 같은 활성화 함수를 사용하는 신경망에서 효과적

02 | Stochastic GD

Stochastic GD

전체 데이터셋에서 하나의 데이터를 랜덤으로 샘플링을 해서 기울기를 계산하는 방식

1. 가중치를 평균 0, 분산 σ^2인 정규분포에서 랜덤 초기화 한다 $\sim N(0,\sigma^2)$
2. 단일 데이터 포인트 i 하나를 선택
3. 그 샘플 하나에 대한 gradient를 계산 $\frac{\partial J_i(W)}{\partial W}$
4. 가중치를 업데이트 해준다 $W \leftarrow W - \eta \frac{\partial J_i(W)}{\partial W}$
5. 수렴할 때까지 위를 반복하고 학습된 가중치 반환

02 | Stochastic GD

Stochastic GD

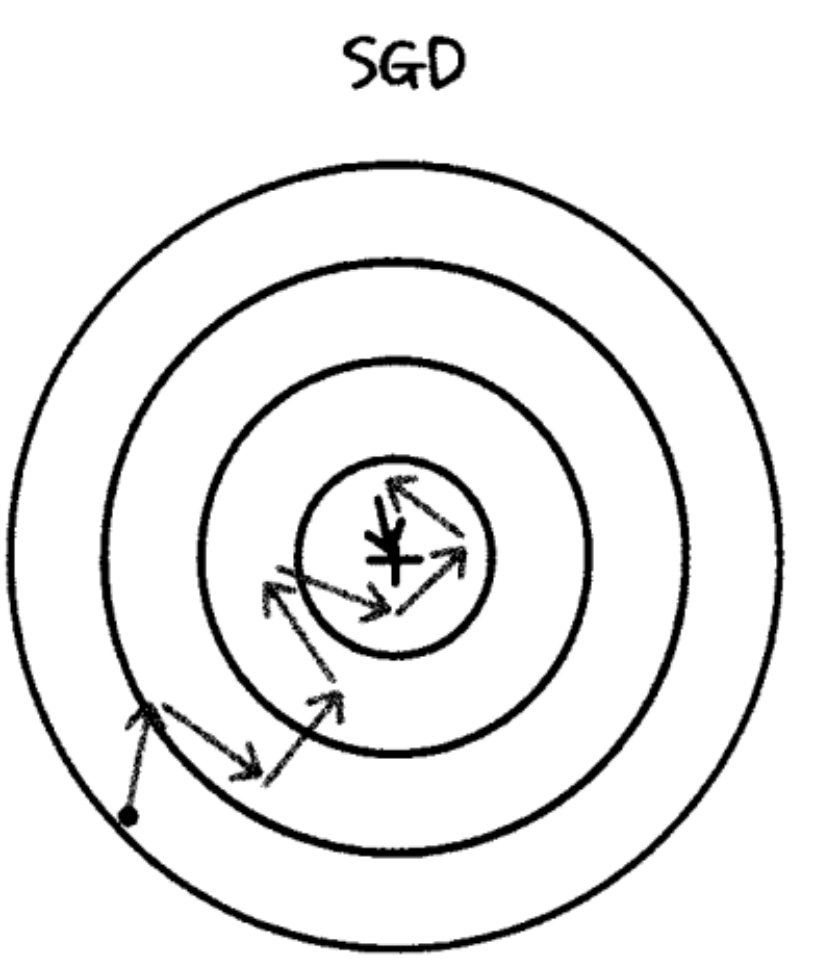

- 학습 속도가 매우 빠르다
- 잦은 업데이트와 노이즈로 인해 Local minimum을 탈출하여 더 나은 해를 찾을 가능성이 높아진다
- 빠르게 Global minimum에 근사 할 수 있어도 수렴하지 못한다는 단점이 있다

03 | Mini-Batch GD

Mini-Batch GD

전체 데이터에서 일부 데이터(Batch-Size)로 나누어 각 배치마다 기울기를 계산해서 θ 갱신하는 방식

1. 가중치를 평균 0, 분산 σ^2 인 정규분포에서 랜덤 초기화 한다 $\sim N(0,\sigma^2)$
2. B개의 데이터로 이루어진 배치(mini-batch) 선택
3. 배치의 평균 기울기 계산 $\frac{\partial J(W)}{\partial W} = \frac{1}{B}\sum_{k=1}^{B}\frac{\partial J_k(W)}{\partial W}$
4. 가중치를 업데이트 해준다 $W \leftarrow W - \eta\frac{\partial J_i(W)}{\partial W}$
5. 수렴할 때까지 위를 반복하고 학습된 가중치 반환

03 | Mini-Batch GD

Mini-Batch GD

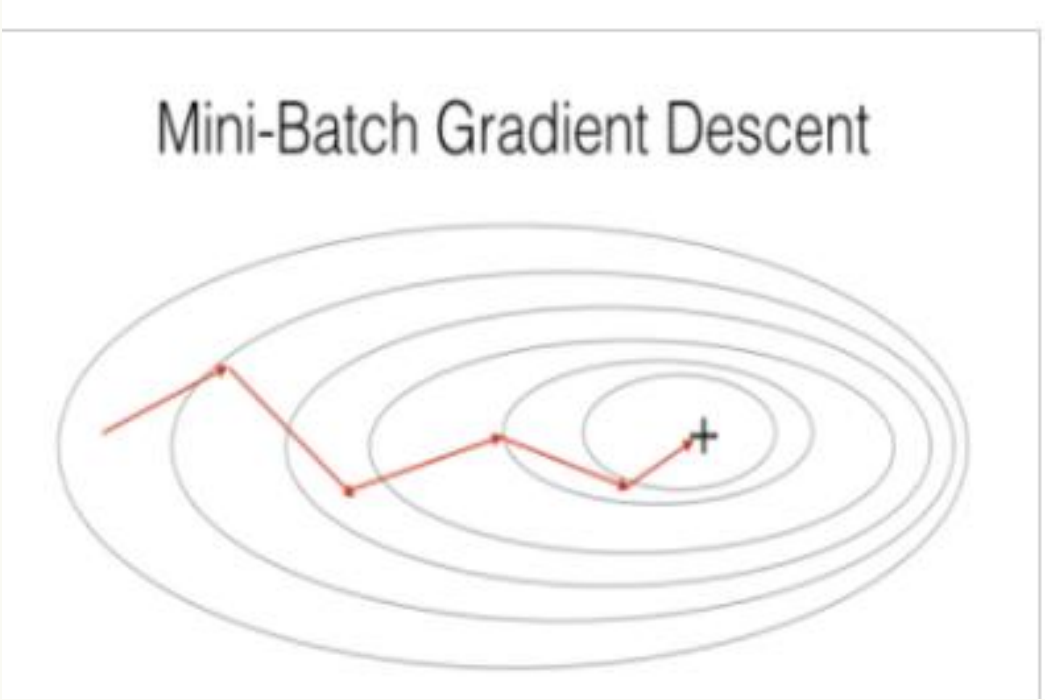

- SGD에 비해 노이즈가 적음
- Batch Size를 잘 지정해야함

04 | BackPropagation 역전파

출력층에서 입력층 방향으로 계산하면서 가중치를 업데이트 하는 방식

- 목표: 손실 L을 줄이기 위해 가중치 W를 업데이트 해야함
- 각 가중치(weight)와 편향(bias)에 대한 손실 함수의 편미분 값 계산 $\frac{\partial L}{\partial W}$
- 역전파 = 이 미분을 빠르고 체계적으로 구하는 방법

04 | BackPropagation 순전파가 필요한 이유

- Forward: 입력 $x \rightarrow$ 예측 $\hat{y}$ 계산
- Loss : $L(\hat{y}, y)$ 계산
- Backward는 이 결과 ($\hat{y}$, 중간 값들)를 이용해 미분을 계산

04 | BackPropagation

Chain Rule

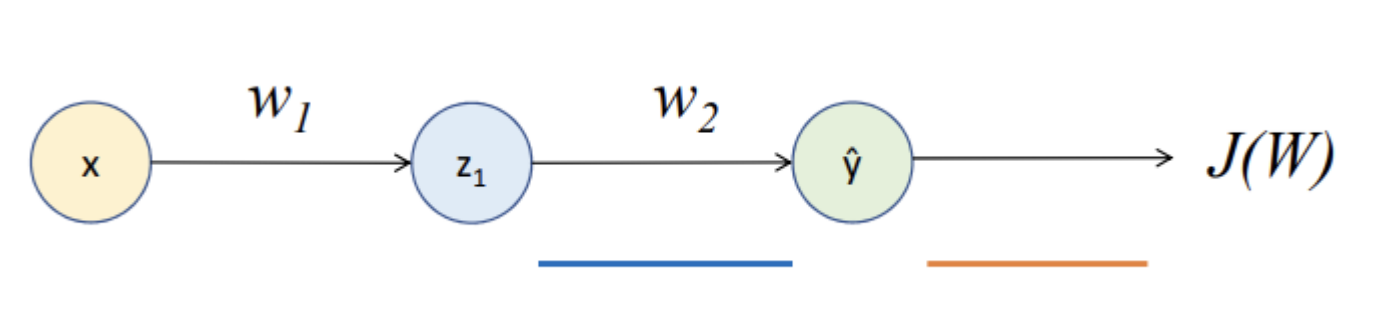

- W2에 대한 편미분 구하는 공식 :

$$\frac{\partial J(W)}{\partial w_2} = \frac{\partial J(W)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial w_2}$$

04 | BackPropagation

Chain Rule

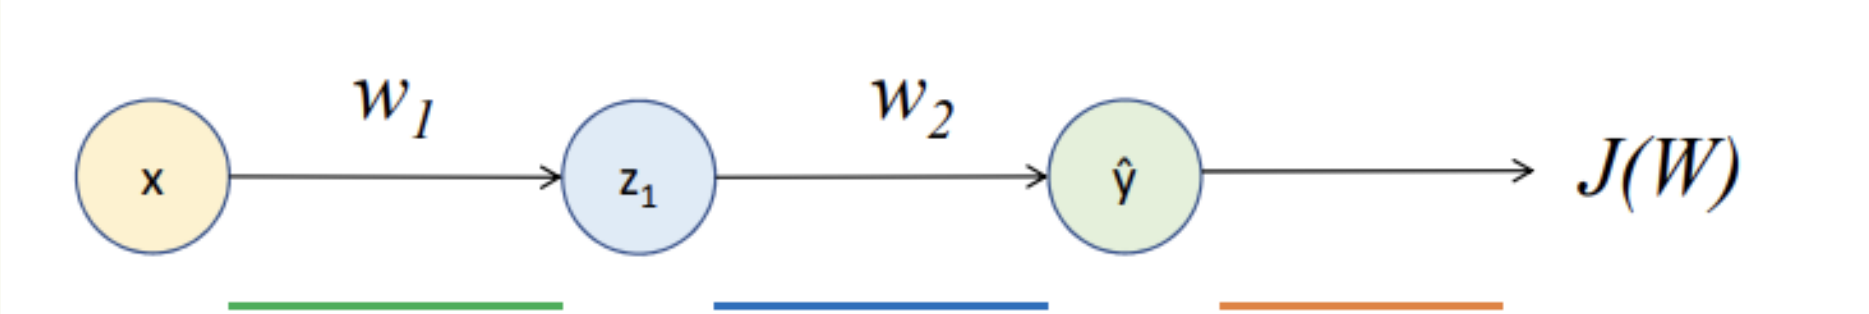

- W1에 대한 편미분 구하는 공식 :

$$\frac{\partial J(W)}{\partial w_1} = \frac{\partial J(W)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial z_1} \times \frac{\partial z_1}{\partial w_1}$$

Gradient Descent & BackPropagation

감사합니다